

基于车辆动态行为特征的交通状态识别研究

李熙莹^{*1,2}, 卢美燕^{1,2}, 何兆成^{1,2}, 苏淑妍^{1,2}, 庞淑敏^{1,2}

(1. 中山大学, 智能工程学院, 广东 深圳 518107; 2. 广东省智能交通系统重点实验室, 广东 深圳 518107)

摘要: 交通状态识别研究对于预防和缓解交通拥堵具有重要的研究价值, 不仅能够为交通管理提供决策支持, 还能有效提升道路的运行效率。传统的交通状态识别方法仅考虑单一的宏观特征参数, 忽视车辆变道行为的影响以及由此产生的车辆间相互干扰, 导致状态划分空间粒度较粗, 状态辨识不够精细化, 难以深入分析交通拥堵的成因。对此, 本文提出一种无人机视角下基于车辆动态行为特征的交通状态识别方法。首先, 该方法结合基于旋转检测框的车辆检测算法(YOLOv8s-OBB)和车辆跟踪算法(BoTSORT)检测和跟踪车辆, 解决水平框中背景像素冗余以及车辆框重叠的问题, 提取车辆空间方向角和旋转4点坐标等更精准的车辆轨迹数据, 并计算微观交通流参数; 其次, 利用获取的车辆空间方向角和旋转位置信息提出车辆动态行为特征参数, 即变道干扰率和车辆方向波动指数; 然后, 结合宏观的平均速度和交通密度参数, 构建多维状态特征空间, 应用于实际道路场景的交通状态识别。最终实验结果表明: 在旋转车辆目标检测中, 该方法的mAP@0.5达到0.987, 输出的车辆轨迹数据稳定且连续; 在交通状态识别中, 在平均速度和交通密度作为宏观特征参数的基础上引入变道干扰率后, 状态识别精确度达到0.983; 进一步, 引入车辆方向波动指数后, 状态识别精确度达到0.987。同时, 根据状态特征空间表征, 可以更加精准地将交通状态划分为4种状态, 即畅通态、平稳态、拥挤态和堵塞态, 从而可以为车辆动态行为量化分析交通状态影响, 为基于无人机视角的交通状态识别提供新的理论参考, 为智能交通系统提供先进的状态精细感知。

关键词: 城市交通; 交通状态识别; 车辆动态行为特征参数; 旋转车辆检测与跟踪; 无人机航拍

Traffic State Recognition Based on Vehicle Dynamic Behavior Characteristics

LI Xiyi^{*1,2}, LU Meiyi^{1,2}, HE Zhaocheng^{1,2}, SU Shuyan^{1,2}, PANG Shumin^{1,2}

(1. School of Intelligent Systems Engineering, Shenzhen Campus of Sun Yat-sen University, Shenzhen 518107, Guangdong, China; 2. Guangdong Provincial Key Laboratory of Intelligent Transportation System, Shenzhen 518107, Guangdong, China)

Abstract: Traffic state recognition research is of great significance for the prevention and mitigation of traffic congestion. It provides decision support for traffic management and also effectively enhances the operational efficiency of roads. Traditional traffic state identification methods typically take into account one single macroscopic characteristic parameter, while overlooking the impact of vehicle lane-changing behaviors and the consequent mutual interference among vehicles. This leads to a relatively coarse granularity in the state division space and insufficient refinement in state identification, thereby hindering in-depth analysis of traffic congestion causes. In response to this, this study proposes a traffic state identification method based on vehicle dynamic behavior characteristics from an Unmanned Aerial Vehicle (UAV) perspective. Firstly, the method combines a vehicle detection algorithm (YOLOv8-OBB) based on rotated bounding boxes and a vehicle tracking algorithm (BoTSORT) to detect and track vehicles, addressing redundant background pixels and overlapping vehicle bounding boxes within horizontal bounding boxes, extract more accurate vehicle trajectory data such as vehicle spatial direction angle and four-point rotation coordinates, and calculate microscopic traffic flow parameters. Secondly, by utilizing the obtained vehicle driving direction angles and rotated position information, this study proposes vehicle dynamic behavior characteristics parameters: lane change interference rate and vehicle direction fluctuation index. Combined with macroscopic average speed and traffic density parameters, a multi-dimensional

收稿日期: 2024-10-16

修回日期: 2024-11-25

录用日期: 2024-12-27

基金项目: 国家自然科学基金/ National Natural Science Foundation of China (U21B2090); 广东省基础与应用基础研究基金/ Guangdong Basic and Applied Basic Research Foundation (2022A1515010361)。

作者简介: 李熙莹(1972—), 女, 陕西西安人, 教授, 博士。

*通信作者: stslxy@mail.sysu.edu.cn

引用格式: 李熙莹, 卢美燕, 何兆成, 等. 基于车辆动态行为特征的交通状态识别研究[J]. 交通运输系统工程与信息, 2025, 25(1): 44–55, 85. [LI X Y, LU M Y, HE Z C, et al. Traffic state recognition based on vehicle dynamic behavior characteristics[J]. Journal of Transportation Systems Engineering and Information Technology, 2025, 25(1): 44–55, 85.]

state feature space is constructed and applied to traffic state identification in actual road scenes. The ultimate experimental results demonstrate that the method achieved an mAP@0.5 of 0.987 in the rotated vehicle detection, with stable and continuous vehicle trajectory data output. In traffic state recognition, by introducing the lane change interference rate based on the average speed and traffic density as macroscopic feature parameters, the state recognition precision reached 0.983. Moreover, incorporating the direction fluctuation index, the state recognition precision reached 0.987. Additionally, according to the state characteristic space representation, the traffic state enables accurate classification into four states: smooth state, steady state, crowded state, and blocked state. This allows for quantitative analysis of the impact of vehicle dynamic behavior on traffic state, and provides novel theoretical insights for traffic state recognition from a UAV perspective, offering advanced fine-grained perception capabilities for intelligent transportation systems.

Keywords: urban traffic; traffic state recognition; vehicle dynamic behavior characteristics parameters; rotated vehicle detection and tracking; UAV aerial photography

0 引言

准确的交通状态识别对于预防和控制交通拥堵至关重要,可以为交通管理提供科学依据,同时,也是提升道路运行效率的关键因素。通过准确识别交通状态,可以有效地进行交通引导和调度,减少拥堵发生,提高道路使用效率。

传统的交通状态识别方法依赖速度^[1]行程时间^[2]等单一指标划分阈值,评估交通态势。然而,单一的指标且统一的划分标准导致该类方法应用在不同时空条件下的实际路段时效果不佳,难以实现广泛且普遍适用的交通状态识别。为更客观准确地描述路段的交通运行状态,国内外一些研究转向提取交通流的多项内在特征参数进行综合分析,其中,最常使用的是交通流的三个基本要素,即流量、速度和密度。黄玲等^[3]使用临界速度和密度结合的方式感知道路是否处于拥堵状态。研究者在流速密的基础上拓展新的衍生参数,例如,道路满载度和速度标准差^[4]、运行速度指数^[5]、路网充裕度^[6]、饱和度和时间占有率^[7]等。TU等^[8]选取加速度和角加速度数据,提高交通流状态分类的准确率。SUN等^[9]融合交通量、速度及占用率,引入权重优化提出交通状态综合识别指数。WANG等^[10]回归分析车流量、车位速度及车头时距等参数,提出耦合度与耦合协调度识别交通状态。上述方法主要依赖宏观交通流参数识别与划分交通状态,然而,这种方法未能充分反映车辆在不同交通状态下动态行为特征的变化,也忽视了交通流的复杂过渡和演变过程,这种局限性导致状态类别划分的粒度较粗,难以满足精细化管理的需求。因此,需要从微观层面考虑构建考虑车辆动态行为特征的交通流参数,实现更为精细的交通状态划分,为深入分析拥堵成因提供有力支持。

在交通流数据获取方面,利用电磁传感器、雷达及GPS等设备获取的交通流参数数据,无法感知

不同交通状态下车辆在空间上的分布情况和车辆间的关系,难以构建微观特征交通流参数。新型采集设备无人机能够从高空提供更广阔的视野,捕捉整体道路空间中车辆的清晰位置和分布形态,不仅可以获取车辆的静态位置信息,还能根据连续帧间的关系得到车辆速度和方向等精细参数。从无人机采集的交通视频中提取交通流参数的方法主要使用基于深度学习的技术,首先,通过目标检测方法检测车辆位置^[11],提取车辆外观特征;然后,通过目标跟踪技术将检测结果依据时序信息匹配连接成车辆轨迹^[12];最后,根据车辆轨迹数据计算交通流参数。QIU等^[13]引入单阶段无头上下文结构改进特征提取,提出YOLO-GNS (You Only Look Once and Optimized by GhostNet and Single Stage Headless)算法,实现高精度的无人机视角特殊车辆检测。李熙莹等^[14]利用基于水平框的车辆检测算法从航拍视频中提取车辆轨迹,计算车辆微观速度、变道行为和潜在冲突,建立车速扰动和变道交织扰动感知模型,进一步,利用熵值法构建归一化的拥堵风险指数,该风险指数能更精细地捕捉短时和局部的拥堵变化,识别交织区交通瓶颈。然而,目前,大多数研究是使用水平边界框检测车辆,其缺点在于水平框内会包含部分背景像素,且车辆检测框之间可能存在重叠,对车辆位置的表示不够精确。采用旋转框进行车辆检测,能够有效地提取车辆在空间中的旋转角度信息,实现精确定位道路上每辆车的位置,精准捕捉车辆动态行为特征,为揭示车辆间的交互关系提供数据支持,从而支持构建更为精细的微观交通特征参数,深入理解和解析交通状态。

综上,目前航拍视角下,道路交通状态识别领域的研究尚存在车辆空间位置信息的精确度不够,车辆动态行为特征未捕捉,微观特征交通参数未构建及交通状态划分不够精细等问题。就上述问题,

本文基于无人机航拍交通视频提出一种基于旋转框的车辆检测和跟踪算法,提取带有车辆旋转角度的精细车辆轨迹数据,提高车辆轨迹数据和交通参数的精度。在此基础上,进一步,提出体现车辆动态行为特征和车辆交互关系的微观特征参数-变道干扰率和车辆方向波动指数,构建多维状态特征空间,并通过真实数据验证新参数的有效性,实现更高准确度的多类交通状态识别。

1 方法

1.1 研究方法框架

实现无人机视角下的交通状态识别,首先,需获取由无人机航拍的交通视频;然后,利用车辆检测跟踪算法从所获取的视频中提取车辆轨迹数据,在此基础上,依据车辆轨迹数据计算宏观和微观交

通特征参数;最后,将宏观交通特征参数作为交通状态识别的依据。因此,本文首先,收集无人机在高空采集的视频数据,为获取更精确的车辆位置信息,利用车辆旋转目标检测网络 YOLOv8s-OBb (YOLOv8s-Oriented Bounding Box) 和车辆跟踪网络 BoTSORT^[15] 从视频中提取车辆个体精细轨迹数据;然后,根据准确的车辆空间位置信息提出描述车辆动态行为特征的微观交通特征参数-变道干扰率和车辆方向波动指数,实现深入解析交通状态特征空间;最后,结合常用的宏观交通特征参数,即平均速度和交通密度,采用极端梯度提升树(eXtreme Gradient Boosting, XGBoost)^[16] 算法实现结合宏观交通参数的4种交通运行状态准确识别。本文的方法框架如图1所示。




图1 基于车辆动态行为特征的交通状态识别方法框架

Fig. 1 Framework of traffic state recognition method based on vehicle dynamic behavior characteristics

1.2 车辆旋转目标检测与跟踪方法

无人机航拍获取的道路交通视频具有显著的优点,即车辆间相互遮挡情况较少且车辆轨迹清晰。但无人机航拍视角下的车辆目标呈现出尺寸较小、方向不固定及目标数量多且分布密集等特点,要求车辆检测算法应具备小尺度目标识别能力,较快的检测速度以及能够连续识别密集目标的特性。因此,本文选取在单阶段目标检测算法领域性能出色的 YOLOv8 算法^[17],采用 YOLOv8s-OBb 检测器,实现检测旋转车辆目标。此外,考虑到跟

踪性能对参数提取准确性的影响,本文选取 BoTSORT 算法作为车辆目标跟踪算法。通过将两者集成,形成旋转车辆检测与跟踪算法 YOLOv8s-OBb-BoTSORT。完整的无人机视角下旋转车辆检测跟踪算法框架如图2所示。

1.2.1 YOLOv8s-OBb 检测网络

YOLOv8 是当前单阶段目标检测算法中表现最为出色的 YOLO 系列的最新版本之一,提供更强的不同尺度目标感知能力,更快的检测速度和更高的准确率。针对通用水平检测框中车辆检测框之

间可能存在重叠的问题,本文采用YOLOv8s检测网络,结合旋转检测框检测车辆,再使用二维高斯分布表示旋转检测框区域,最后,采用概率交并比ProbIoU (Probabilistic Intersection-over-Union)^[18]作

为旋转检测框的损失函数,形成YOLOv8s-OBb旋转车辆目标检测网络,更准确地获取车辆目标的位置和倾斜方向角。该网络具备对小尺度车辆目标的感知能力,较快的检测速度以及较高的准确度。




图2 旋转车辆检测和跟踪算法

Fig. 2 Rotated vehicle detection and tracking algorithm

(1) 网络结构

YOLOv8s-OBb检测网络的结构由输入(Input)、主干网络(Backbone)、颈部(Neck)和检测头(Head)这4个部分组成,模型架构如图3所示。输入端负责将输入图片调整到合理的尺寸,并进行缩放和Mosaic数据增强等操作。主干网络用于提取目标特征信息,采用Conv和C2f等模块。颈部主要负责特征信息的融合,采用特征金字塔FPN和路径

聚合结构PAN。检测头负责生成不同目标的置信度和位置信息,采用解耦头结构。检测的具体流程是:首先,基于主干网络提取输入图像的多尺度特征;随后,在颈部对3种不同尺度的特征进行特征融合和增强,并通过检测头预测目标旋转框信息和类别(x, y, w, h, θ , 类别);最后,基于旋转框定位损失函数和类别损失函数进行训练。




图3 旋转检测网络模型架构

Fig. 3 Rotated detection network model architecture

(2) 旋转框定义

相比于通用水平检测框使用中心点坐标(x, y)、检测框的宽度(w)和高度(h)描述边界框的尺寸和位置,本文在此基础上,增加旋转角度(θ)的检测,形成旋转检测框描述车辆的精确位置,(水平框和旋转框对比如图4所示, θ 通常是相对于水平轴的旋转角度($-90^\circ \sim 90^\circ$)。采用二维高斯分布表示旋转检测框所覆盖的区域,其建模过程的原理如图5所示。




图4 水平框(左)和旋转框(右)

Fig. 4 Rotated bounding boxes (left) and horizontal bounding boxes(right)




图5 通过二维高斯分布建模旋转检测框的原理

Fig. 5 A schematic diagram of modeling a rotating bounding box by a two-dimensional Gaussian distribution

二维高斯分布由均值向量 $\mu = (x_0, y_0)^T$ 和协方差矩阵 Σ 描述。在车辆目标检测中,将回归任务中的参数表示为 $(x_0, y_0, a', b', \theta)$,即旋转检测框的输出形式。旋转检测框转化为二维高斯分布遵循假设:目标区域为二维二元区域 Ω ,且符合均匀概率密度函数分布,则该分布的 μ 和 Σ 为

$$\Sigma = \begin{bmatrix} a & c \\ c & b \end{bmatrix} = R_\theta \begin{bmatrix} a' & 0 \\ 0 & b' \end{bmatrix} R_\theta^T = \begin{bmatrix} a' \cos^2 \theta + b' \sin^2 \theta & \frac{1}{2}(a' - b') \sin 2\theta \\ \frac{1}{2}(a' - b') \sin 2\theta & a' \sin^2 \theta + b' \cos^2 \theta \end{bmatrix} \quad (1)$$

$$\begin{cases} \mu = \frac{1}{S} \int_{x \in \Omega} x \\ \Sigma = \frac{1}{S} \int_{x \in \Omega} (x - \mu)(x - \mu)^T \end{cases} \quad (2)$$

式中: a, b, c 分别为旋转检测框的宽,高,角度; R_θ 为二维旋转矩阵,和 θ 相关; S 为区域 Ω 的面积。

(3) 损失函数

损失函数包括两部分:旋转框检测损失和类别损失。其中,类别损失函数为二元交叉熵损失函数 BCE(B_L)。旋转框检测损失函数为概率交并比损失函数 ProbIoU,其主要采用 Hellinger 距离度量两个二维高斯分布的相似性。给定旋转框真值对应的高斯分布 $q = (x_2, y_2, a_2, b_2, q_2)$,旋转框预测值对应的高斯分布 $p = (x_1, y_1, a_1, b_1, q_1)$,旋转框检测损失可表示为 L_1 和 L_2 , L_1 和 L_2 均可微,并且当 $p = q$ 时,达到最小值0,对象缩放不变。在训练过程中,先使用 L_2 进行初步对齐,之后采用 L_1 更好地拟合二维高斯分布。

$$B_L = -\frac{1}{M} \sum_{i=1}^M [y_i \ln(p_i) + (1 - y_i) \ln(1 - p_i)] \quad (3)$$

$$B_c(p, q) = \int_{R^2} \sqrt{p(x)q(x)} dx \quad (4)$$

$$B_d(p, q) = -\ln B_c(p, q) \quad (5)$$

$$H_d(p, q) = \sqrt{1 - B_c(p, q)} \quad (6)$$

$$L_1(p, q) = H_d(p, q) = 1 - \text{ProbIoU}(p, q) \in [0, 1] \quad (7)$$

$$L_2(p, q) = B_d(p, q) = -\ln[1 - L_1^2(p, q)] \in [0, \infty] \quad (8)$$

式中: M 为样本数量,为第 i 个样本的真实标签; p_i 为模型预测第 i 个样本属于正类的概率; B_c 为巴氏系数,可以表征两个高斯分布的相似度; R^2 为二维实数空间; B_d 为巴氏距离; H_d 为真实距离。

1.2.2 BoTSORT 跟踪网络

无人机飞行过程中的抖动以及道路两旁树木的遮挡容易造成目标丢失和错误匹配问题,对此,本文采用前沿的 BoTSORT 算法^[15]跟踪车辆,该算法通过考虑相机运动补偿改善相机抖动问题,联合目标运动特征和外观特征进行精准的目标匹配,改善目标丢失和错误匹配问题,支撑精细的车辆轨迹提取。其具体过程如下。

(1) 检测目标和进行相机运动估计。相机运动补偿模块利用全局运动估计技术表示背景运动,通过调用 OpenCV 库函数,提取图像关键点,并利用稀疏光流跟踪特征点,使用随机抽样一致性算法计算放射变换矩阵,估计相机的旋转和平移矩阵,有效改善因相机运动导致的车辆 ID 切换和丢失问题。

(2) 对高分检测框和卡尔曼滤波算法得到的预测框用 ReID 和 IoU 进行关联。采用分别估计宽和高的方式改进卡尔曼滤波器的状态向量,实现精确估计目标状态。

(3) 对低分检测框和未关联目标利用 IoU 进行关联。结合目标前后帧的 IOU 距离矩阵和外观特征的余弦距离矩阵进行目标关联,过滤距离较远的目标,改善目标遮挡和模糊影响,提升跟踪效果。

通过上述流程,BoTSORT 算法实现轨迹的关联和更新,提供一种鲁棒的多目标跟踪解决方案。

1.3 车辆动态行为特征参数

从微观层面解析和识别交通状态,需依托于能够反映车辆个体与群体行为变化的微观交通特征参数。为能够更精确地体现车辆在道路空间上的相互影响,需要深入研究并合理设计相关参数。不仅有助于提升交通状态识别的准确性,还对理解交通流的内在运行机制具有重要意义。因此,本文提出两个微观特征参数,即变道干扰率和车辆方向波

动指数。

变道干扰率体现路段车辆变道和相互干扰的情况,不仅量化变道行为的发生概率,还衡量车辆对周边车辆的影响,体现交通流的紊乱程度。车辆方向波动指数能够量化车辆在行驶过程中方向变化的不稳定性,和意图变道产生的影响和干扰,以及由此形成的车辆群体行驶的不规律性,通过捕捉车辆群体在路段空间上的变动,揭示车辆行驶路线中的波动性,反映车辆群体动态的混乱程度。结合这两个微观特征参数,可以全面地捕捉车辆行为的动态变化和复杂性,从而以更细致和精确的方式描绘交通流的状态,实现准确感知交通状态。

1.3.1 变道干扰率

变道干扰率通过变道率和干扰率两个参数计算。变道率量化车辆在交通流中改变车道的频率,直接关联到车辆个体在空间位置上的自主变化;干扰率衡量其他车辆对特定车辆行驶路径和速度选择的影响程度,量化车辆个体在多车环境中受到周围车辆的动态影响。

(1) 变道率

为表示车辆实际变道对交通流产生的影响,本文提出以下计算方法提取路段整体的变道率,体现路段整体的车辆变道情况。

提取得到的车辆行驶方向角 θ 的范围为 $-90^\circ \sim 90^\circ$ (0° 为水平车道线方向),每个交通流状态时刻中,以 10 s 前的方向角为初始角度,记录每个车辆的初始角度 θ_0 ;当车辆变道时,行驶方向角 θ 开始出现持续增大或持续减小的状态,记录 $\Delta\theta = |\theta - \theta_0|$ 。当 $\Delta\theta > 2^\circ$ 时,判断车辆出现变道行为,如图 6 所示。 t 时刻下,路段的车辆变道率 $C(t)$ 为

$$C(t) = n_c(t)/n(t) \quad (9)$$

式中: $n_c(t)$ 为 t 时刻下路段内正处于变道状态的车辆数; $n(t)$ 为路段总车辆数。




图 6 车辆变道过程

Fig. 6 Sketch map of vehicle lane change process

(2) 干扰率

为表示周围车辆对车辆产生的影响,本文提出以下计算方法提取路段整体的干扰率,体现路段中所有车辆相互之间的干扰程度。

通过在车辆轮廓外设置合理的安全空间,计算车辆与相邻车辆的安全空间是否有重叠,如图 7 所示,存在重叠即可以判断该时刻车辆间存在相互干扰,车辆处于被干扰的状态。 t 时刻下,车辆干扰率 $I(t)$ 为

$$I(t) = n_i(t)/n(t) \quad (10)$$

式中: $n_i(t)$ 为 t 时刻下路段内正处于干扰状态的车辆数。




图 7 车辆处于干扰状态

Fig. 7 Sketch map of vehicle in interference state

车辆安全空间是车辆的缓冲区,其边界大小通过车辆自身的长宽、行驶速度、反应时间和横向安全距离确定。车辆安全空间如图 8 所示,其中, w 为车辆长度, h 为车辆宽度, τ 为车辆在紧急情况下的反应时间, v 为车辆行驶速度, τv 为车辆与跟驰的前车横向安全距离, W_c 为车辆与相邻车辆的横向安全距离。设置 τ 为 0.5 s, W_c 为 1.4 m,结合已有的车辆精确坐标信息可以计算车辆安全空间的 4 点坐标 $(x_1, y_1, x_2, y_2, x_3, y_3, x_4, y_4)$ 。




图 8 车辆安全空间

Fig. 8 Sketch map of vehicle safety space

本文提出的变道干扰率 $R(t)$ 是将变道率和干

扰率相加,再进行归一化,即

$$R(t) = C(t) + I(t) \quad (11)$$

在交通流理论中,车辆的变道行为被视为交通流稳定性的一个重要因素。当变道干扰率较低时,表明车辆能够平稳地在车道间移动,交通流处于较高的自由态;当变道干扰率较高,表明较多车辆进行变道或周围存在干扰,交通流比较不稳定,交通流处于不自由态。

1.3.2 车辆方向波动指数

在交通密度较高、车辆间距紧凑及流动性减弱的路况中,当某车道的通行效率低下时,处于该车道的车辆倾向于采取变道或加塞的行为,但由于车辆间距更紧,车辆移动缓慢,变道行为更耗时,且常常无法成功变道。此时,变道干扰率无法体现道路空间整体的混乱程度,如图9所示。因此,本文为表示车辆变道倾向在路段上的方向波动导致的路段混乱,提出车辆方向波动指数。



图9 无序和密集的车辆分布示例

Fig. 9 Examples of chaotic and dense vehicle distribution

当车辆尝试变道时,车辆的行驶方向角在一段时间内会呈现一定的角度变化。因此,统计路段上车辆行驶方向角的变化可以反映路段总体的车辆方向混乱情况。在某个交通流状态时刻下,以每10 s为观测时间,计算路段内所有车辆行驶方向角最大值和最小值的差值之和,可以得到整体的车辆方向波动指数。 t 时刻下,车辆方向波动指数 $F(t)$ 为

$$F(t) = \sum_{i=1}^N [\max(\theta_i) - \min(\theta_i)] \quad (12)$$

式中: N 为观测时间内的路段总车辆数; θ_i 为车辆 i 在观测时间内所有时间点的角度值集合; $\max(\theta_i)$ 为车辆 i 的角度值集合 θ_i 中的最大值; $\min(\theta_i)$ 为车辆 i 的角度值集合 θ_i 中的最小值。

当车辆方向波动指数较低时,表明车辆群体能

够保持较为稳定的行驶路径,反映交通流的畅通和有序;当车辆方向波动指数较高时,表明较多车辆在行驶过程中频繁改变方向,反映交通流的混乱和波动,说明交通流处于不自由态。

1.4 交通状态识别算法选择

在完成交通特征参数提取和计算后,需要选择合适的机器学习算法识别不同的交通状态。极端梯度提升树算法XGBoost通过逐步构建一系列弱学习器,并将其组合成一个强学习器,提高预测性能,被广泛应用于回归和分类问题。在处理交通状态识别这类分类问题时,XGBoost能够学习数据中的复杂模式,准确区分交通的不同状态;同时,XGBoost在构建决策树时,采用并行处理和缓存优化等策略,大大提升算法的运行效率,更快地提供交通流状态识别结果。XGBoost算法的具体流程如下:

- (1) 初始化一个简单模型;
- (2) 计算初始模型预测值与实际值之间的残差;
- (3) 训练一个新决策树预测残差,减小误差;
- (4) 将新树加入现有模型中,提升整体预测能力;
- (5) 重复上述过程,不断添加新树,直至达到预定树的数量或误差降到可接受范围。最终输出各时刻对应的交通状态预测值。

2 数据集

2.1 路段交通视频数据

本文的研究数据来源于使用DJI Phantom 4型号无人机在120~130 m高度悬停采集的广州市广州大桥路段两个早高峰时段,共11 h视频,该拍摄路段总长度为1100 m,7个场景,如图10所示。将采集的视频数据以每10 s为间隔,划分成3761个独立的交通流状态时刻,为进一步计算交通特征参数和实验分析提供数据支撑。

2.2 旋转车辆目标标注数据

为给旋转目标检测网络提供足够的训练和测试数据,从收集的无人机航拍视频中获取在不同路段不同时间下的869张图片(1920 pixel×1080 pixel),进行旋转目标框的标注,根据《公路工程技术标准》,按照车长6 m为分界线,将城市快速路场景下道路的车辆目标分为大型车(Large Vehicle)和小型车(Small Vehicle)两类,Large Vehicle类为3453个标注框,Small Vehicle类为68222个标注框。



图 10 航拍路段场景

Fig. 10 Aerial road scene map

2.3 车辆轨迹和交通流特征参数数据

利用提出的YOLOv8-OBB-BoTSORT算法,从11 h视频中获取每个视频片段的原始车辆跟踪结果,即每个车辆在每帧中的像素信息(帧号,编号, x, y, w, h, θ , 类别)。在视频数据采集时,预先设置标定板,记录的标定板比例可以作为道路标定信息。结合视频图像信息、道路标定信息和车道信息,在原始车辆跟踪数据的基础上,可以还原每个车辆的真实物理位置信息,得到精细个体轨迹数据,包括:时间(s)、车辆ID、车辆中心点水平坐标、车辆中心点垂直坐标、车长(m)、车宽(m)、车辆行驶方向角 θ 、车辆类型class(0为小车,1为大车)、水平方向速度($\text{km} \cdot \text{h}^{-1}$)、垂直方向速度($\text{km} \cdot \text{h}^{-1}$)和速度($\text{km} \cdot \text{h}^{-1}$)。总共提取到63929条车辆轨迹,其中,小型车辆61463条轨迹,占比96.14%;大型车辆2466条轨迹,占比3.86%。

基于上述轨迹数据,提取交通流状态识别所需的宏微观交通流特征参数。宏观特征参数为路段平均速度 V ($\text{km} \cdot \text{h}^{-1}$)和交通密度 D ($\text{veh} \cdot \text{km}^{-1}$)。微观交通特征参数为变道干扰率 R 和车辆方向波动指数 F 。

$$V = \left(\sum_{i=1}^N v_i \right) / N \quad (13)$$

$$D = N / L \quad (14)$$

式中: v_i 为第 i 辆车的平均速度($\text{km} \cdot \text{h}^{-1}$); L 为路段

的长度(km)。

根据4个参数的计算式,本文计算得到3761个独立交通流状态时刻对应的4个交通特征参数:路段平均速度、交通密度、变道干扰率及车辆方向波动指数,作为交通状态识别的实验数据。

2.4 多分类交通状态数据集

由于后续的交通状态识别工作要以真值作为指标评估的依据,本文以采集的宏观交通特征参数为基础,即路段平均速度 V 和交通密度 D ,结合数据分析与人工校正的方法,对交通状态进行多分类定义,确定4个类别的交通状态定义及其相应的数量。这种划分方式以数据为依据,为交通状态的深入分析提供基础的分类框架,有助于理解交通流在不同状态下的运行特性。

本文按一定的区间大小将 V - D 划分为多个网格区间,对所有交通状态参数组进行可视化,如图11所示,图11中,分箱高度表示该网格区间的频数。从图11可以看出, V - D 数据呈现个显著的峰值,且数据之间存在明显的过渡区域和差异。从总体上看,可以依据这些特征将数据划分为4种不同的数据分布类型,初步将交通状态划分为4种不同类型。




图 11 平均速度-交通密度数据网格可视化

Fig. 11 Average speed-traffic density data grid visualization

上述通过数据分析初步划分得到的交通状态容易在两个状态的边界产生混淆,本文在此基础上,基于路段交通状态差异、车辆间关系及车辆行为变化等因素,以人工判别的方式实现精细划分交通状态,最终确定4种交通状态定义:畅通态、平稳态、拥挤态及堵塞态。各交通状态的无人机视频画面如图12所示,其中,图12(a)为畅通态,即车辆自由行驶、速度快、道路占有率低及车辆间无干扰;图12(b)为平稳态,即小部分车辆跟驰行驶、速度较

快、道路占有率提高及车辆间干扰较小;图12(c)为拥挤态,大部分车辆跟驰行驶、速度慢、道路占有率较高及车辆间干扰加剧,车辆群流动性受到制约,有个别车辆停滞车道;图12(d)为堵塞态,即车辆间距小、速度很慢、道路占有率很高及车辆间严重干扰,车辆群流动性严重被制约,有较多车辆停滞车道。交通状态数据集中各交通状态的真值数量和占比如表1所示。



图12 道路交通状态分类对应场景示例
Fig. 12 Examples of scene corresponding to road traffic state classification

表1 4种交通状态的真值数量和占比
Table 1 Number and proportion of true values of four traffic states

状态名称	数量	占比/%
畅通	1327	35.28
平稳	334	8.88
拥挤	1116	29.68
堵塞	984	26.16

3 实验结果与分析

3.1 旋转车辆目标检测与跟踪效果

为验证YOLOv8-OB-BoTSORT算法在车辆旋转目标检测与跟踪方面的高效性,在自建的旋转车辆目标标注数据集上,以8:1:1的比例划分训练集、验证集及测试集。利用目标检测领域常用的两类指标AP和mAP评价检测效果。AP为平均精度,是某类别精度-召回率曲线(Precision-Recall Curve)与坐标轴的面积。mAP为平均精度均值,是数据集中各类别检测准确率(AP)的均值。

实验中,采用的设备为i7-14700K处理器,NVIDIA GeForce RTX4080 16 G显卡,深度学习框架为Pytorch1.11.0,Python版本为3.8.8。训练过程中,实验参数的设置:训练轮数为100轮,输入图像

大小为1024 pixel×1024 pixel,批大小为16。YOLOv8s-OB-BoTSORT检测算法在该数据集上的测试结果如表2所示。整体的mAP@0.5达到了0.987,大型车辆和小型车辆的AP@0.5分别达到0.992和0.982,证明所提算法在实际应用中的有效性和可靠性,能够满足航拍场景下对于车辆精确检测的需求。

表2 车辆检测测试结果
Table 2 Test result of vehicle detection

类别	AP@0.5	mAP@0.5
大车	0.992	0.987
小车	0.982	

在车辆跟踪方面,BoTSORT算法可以实现稳定的车辆跟踪,如图13所示,提供稳定且连续的车辆轨迹信息,为交通特征参数的计算提供数据基础。




图13 BoTSORT算法车辆跟踪效果展示
Fig. 13 BoTSORT algorithm vehicle tracking effect display

3.2 交通状态识别效果

为验证本文提出的变道干扰率和车辆方向波动指数在区分和刻画不同交通状态方面的有效性,本文对比不同特征参数组合方法的交通状态识别效果,方法1,为黄玲等^[3]提出的方法,即仅使用特征参数 V 和 D ;方法2,为使用特征参数 V 、 D 及 R ;方法3,为使用特征参数 V 、 D 、 R 及 F ,即本文方法。

3.2.1 整体交通状态识别结果

本文采用XGBoost算法,实验中,以7:3的比例划分训练集和测试集,分别基于上述3种特征参数组合方法进行训练和测试,并采用精确度、召回率以及F1分数3个关键指标综合评价交通状态识

别的性能。测试集上的整体实验结果汇总如表3所示,为不同方法的性能评价提供定量的比较依据。此外,为验证 XGBoost 算法的优越性,在方法1中,选取机器学习算法支持向量机(Support Vector Machine, SVM)^[19]和随机森林(Random Forest, RF)^[20]进行算法比较实验。通过对比测试集上的性能评价指标,验证 XGBoost算法在交通状态识别方面的表现最为优异和均衡。

方法2的实验结果显示,引入变道干扰率 R

后,相对方法1的精确度提升了1.76%,召回率提升了7.06%,F1分数提升了5.06%;当方法3进一步引入车辆方向波动指数 F 作为第4个特征参数时,精确度提升2.17%,召回率提升7.28%,F1分数提升5.38%。综上,相比于方法1只使用两个特征参数,方法3的实验指标显著提升,表明变道干扰率和车辆方向波动数的引入可以有效提高整体交通状态识别的准确度。

表3 测试集整体的精确度、召回率及F1分数
Table 3 Overall precision, recall, and F1 score of test set

方法	特征参数	算法	精确度	召回率	F1 分数
方法1 ^[9]	V, D	SVM	0.968	0.892	0.918
		RF	0.944	0.775	0.780
		XGBoost	0.966	0.906	0.929
方法2	V, D, R	XGBoost	0.983	0.970	0.976
方法3 (本文方法)	V, D, R, F	XGBoost	0.987	0.972	0.979

3.2.2 4种交通状态详细识别结果

为展示和分析所提参数在4种交通状态识别上的具体效果,分别统计4种交通状态对应的实验指标结果,如表4所示。结果表明,引入变道干扰率和车辆方向波动指数显著提升4类交通状态识别的准确率和稳定性,尤其是拥挤态和堵塞态的辨

识,达到最优的识别效果。在平稳态下,方法3的召回率提高了30.42%,F1分数提升了15.10%,显著减少平稳态这一过渡态被识别成其他状态的情况。在拥挤态和堵塞态下,3项指标均提升2%以上,有效改善拥挤态和堵塞态的易混淆问题。

表4 4种交通状态识别的精确度、召回率及F1分数对比
Table 4 Comparison of precision, recall, and F1 scores for four traffic state recognitions

交通状态	方法	特征参数	精确度	召回率	F1 分数
畅通	方法1	V, D	0.975	1.000	0.987
	方法2	V, D, R	0.986	1.000	0.993
	方法3	V, D, R, F	0.986	1.000	0.993
平稳	方法1	V, D	1.000	0.697	0.821
	方法2	V, D, R	0.983	0.894	0.937
	方法3	V, D, R, F	0.984	0.909	0.945
拥挤	方法1	V, D	0.929	0.963	0.946
	方法2	V, D, R	0.985	0.978	0.982
	方法3	V, D, R, F	0.989	0.985	0.987
堵塞	方法1	V, D	0.962	0.965	0.963
	方法2	V, D, R	0.981	0.992	0.987
	方法3	V, D, R, F	0.988	0.992	0.990

3.2.3 典型场景案例分析

本文采用5个典型场景分析变道干扰率和车辆方向波动指数在交通状态辨识中的作用,3种方法的交通状态识别效果如表5所示。在前4个场景中,变道干扰率 R 提供额外的车辆动态行为信息,可以准确监测车辆群的流动情况,提升交通状态识别效果。在5号场景中,车辆方向波动指数 F 可以精准捕捉道路空间上车辆的混乱性,精准地区分拥

挤状态和堵塞状态,表明其能有效辨识低速度、高密度及车流混乱场景下的交通状态。5个具体场景对应的各方法状态识别效果和原因分析如下:

(1) 1号场景($V=15.60\text{ km}\cdot\text{h}^{-1}$ 、 $D=38.72\text{ veh}\cdot\text{km}^{-1}$ 、 $R=0.30$ 、 $F=93.69^\circ$)中,部分路段道路交通密度适中,小部分车辆以较慢速度行驶时,方法1会误将平稳态识别为拥挤态,方法2和方法3可以准确识别为平稳态, R 和 F 可以有效地识别车辆群体处

于自由流动的状态,不受个别低速车辆的影响,更准确地判断路段处于平稳态。

(2) 2号场景($V=20.55\text{ km}\cdot\text{h}^{-1}$ 、 $D=52.10\text{ veh}\cdot\text{km}^{-1}$ 、 $R=0.56$ 、 $F=152.16^\circ$)的个别车道出现排队现象,个别车辆停滞,但部分车辆速度较高时,方法1无法识别拥挤态,方法2和方法3可以准确识别为拥挤态。 R 和 F 可以捕捉到车辆动态变化的细节,感知路段是否出现局部排队现象,即使在部分车辆速度较高的情况下也能准确识别出拥挤状态。

(3) 3号场景($V=11.00\text{ km}\cdot\text{h}^{-1}$ 、 $D=84.85\text{ veh}\cdot\text{km}^{-1}$ 、 $R=0.43$ 、 $F=159.27^\circ$)的车辆流动性降低,个别车辆停滞,部分车道车辆速度较低时,方法1会误将拥挤态识别为堵塞态,方法2和方法3可以准确识别拥挤态。 R 和 F 能够精准地识别局部车道多车排队的情况,同时,能有效辨识最外车道部分车辆

未受前者影响而保持一定流动性的拥挤状态。

(4) 4号场景($V=13.15\text{ km}\cdot\text{h}^{-1}$ 、 $D=84.41\text{ veh}\cdot\text{km}^{-1}$ 、 $R=0.58$ 、 $F=171.68^\circ$)的大部分车道排队,车辆群流动性严重下降时,速度和密度参数无法识别堵塞态,方法2和方法3可以准确识别堵塞态。 R 和 F 能够识别在行驶过程中车辆个体间的显著影响和制约以及车辆群体流动性的波动,准确地识别出堵塞状态。

(5) 5号场景($V=16.58\text{ km}\cdot\text{h}^{-1}$ 、 $D=77.56\text{ veh}\cdot\text{km}^{-1}$ 、 $R=0.40$ 、 $F=218.48^\circ$)的道路中出现多个瓶颈点,较多车辆停滞时,方法1和方法2均无法识别出较多车辆在堵点前后混乱行驶的状态,方法3通过车辆方向波动指数 F 能够有效捕捉空间上的混乱性,识别出由多个分散堵点引起的堵塞状态,为准确识别复杂的交通堵塞状态提供关键信息。

表5 部分测试样本及3个方法识别结果
Table 5 Some test samples and recognition results of three methods

场景编号	交通场景 (箭头连接的矩形框内标识为同一辆车)	状态真值	方法1	方法2	方法3
1	09:08:56	平稳	拥挤	平稳	平稳
	09:09:01				
2	08:05:32	拥挤	平稳	拥挤	拥挤
	08:05:37				
3	08:45:26	拥挤	堵塞	拥挤	拥挤
	08:45:31				
4	08:14:44	堵塞	拥挤	堵塞	堵塞
	08:14:49				
5	08:19:03	堵塞	拥挤	拥挤	堵塞
	08:19:08				

4 结论

本文提出一种基于旋转检测框的车辆目标检测与跟踪算法YOLOv8s-OB-BoTSORT,该方法

采用旋转目标框的形式精确标注无人机航拍视频中的车辆,采用YOLOv8s-OB-BoTSORT算法在车辆跟踪方

面表现优异,能获取稳定且连续的车辆轨迹信息,丰富车辆空间信息,为微观交通行为的精细化研究提供新的视角和数据支持。在速度和密度作为宏观特征参数的基础上,提出两个体现车辆动态行为特征的微观特征参数:变道干扰率和车辆方向波动指数,实验结果表明,变道干扰率能够有效识别车辆群的频繁变道行为、车辆个体受到其他车辆干扰的状态,以及在拥挤和堵塞状态下车辆群流动性受到制约的情况。而车辆方向波动指数能够进一步区分拥挤和堵塞两种不同的交通行为,为拥堵状态提供更精细的划分标准。通过结合变道干扰率和车辆方向波动指数,交通状态识别精度显著提升至0.987,有效增强对易混淆交通状态的辨识能力。

参考文献

- [1] 郭群勇, 胡振华, 张红. 基于多源轨迹数据的城市交通状态精细划分与识别[J]. 交通运输系统工程与信息, 2020, 20(1): 83-90. [WU Q Y, HU Z H, ZHANG H. Fine division and identification of urban traffic status based on multi-source trajectory data[J]. Journal of Transportation Systems Engineering and Information Technology, 2020, 20(1): 83-90.]
- [2] 谢东繁, 贾惠迪, 李春艳, 等. 基于网格交通状态分类的行程时间规律挖掘与计算[J]. 交通运输系统工程与信息, 2022, 22(3): 168-178. [XIE D F, JIA H D, LI C Y, et al. Mining and calculating travel time based on classification of grid traffic state[J]. Journal of Transportation Systems Engineering and Information Technology, 2022, 22(3): 168-178.]
- [3] 黄玲, 吴泽荣, 洪佩鑫, 等. 基于地空信息融合的无人机交通状态感知方法研究[J]. 中国公路学报, 2021, 34(12): 249-261. [HUANG L, WU Z R, HONG P X, et al. Research on UAV traffic state perception method based on ground and air information fusion[J]. China Journal of Highway and Transport, 2021, 34(12): 249-261.]
- [4] 谷远利, 杜恒, 陆文琦. 多源数据融合驱动的城市快速路交通状态划分[J]. 交通运输系统工程与信息, 2024, 24(3): 213-220, 231. [GU Y L, DU H, LU W Q. Traffic state division of urban expressway driven by multi-source data fusion[J]. Journal of Transportation Systems Engineering and Information Technology, 2024, 24(3): 213-220, 231.]
- [5] AFRIN T, YODO N. A probabilistic estimation of traffic congestion using Bayesian network[J]. Measurement, 2021, 174: 109051.
- [6] CHENG Z, WANG W, LU J, et al. Classifying the traffic state of urban expressways: A machine-learning approach [J]. Transportation Research Part A: Policy and Practice, 2020, 137: 411-428.
- [7] 白骅, 王建军, 蒋意眉. 基于点、线、面层次的公路网交通运行状态评价[J]. 中国公路学报, 2018, 31(11): 197-204. [BAI H, WANG J J, JIANG Y M. Evaluation of highway network traffic operation state based on point, line, and area[J]. China Journal of Highway and Transport, 2018, 31(11): 197-204.]
- [8] TU W, XIAO F, LI L, et al. Estimating traffic flow states with smart phone sensor data[J]. Transportation Research Part C: Emerging Technologies, 2021, 126: 103062.
- [9] SUN D, AI Y, WANG L. Freeway traffic safety state classification method based on multi-parameter fusion clustering[J]. Modern Physics Letters B, 2022, 36(20): 2250088.
- [10] WANG Y, FU Q, WANG X. A traffic status evaluation method of expressway merging area based on improved coupling theory[J]. Modern Physics Letters B, 2022, 36(19): 2150616.
- [11] 张河山, 谭鑫, 范梦伟, 等. 无人机高空航拍视角下小尺度车辆精确检测方法[J]. 交通运输系统工程与信息, 2024, 24(3): 299-309. [ZHANG H S, TAN X, FAN M W, et al. Accurate detection method of small-scale vehicles from perspective of unmanned aerial vehicle high-altitude aerial photography[J]. Journal of Transportation Systems Engineering and Information Technology, 2024, 24(3): 299-309.]
- [12] BISIO I, GARIBOTTO C, HALEEM H, et al. Vehicular/non-vehicular multi-class multi-object tracking in drone-based aerial scenes[J]. IEEE Transactions on Vehicular Technology, 2023, 72(12): 4961-4977.
- [13] QIU Z, BAI H, CHEN T. Special vehicle detection from UAV perspective via YOLO-GNS based deep learning network[J]. Drones, 2023, 7(2): 117.
- [14] 李熙莹, 梁靖茹, 张伟斌, 等. 基于航拍视频构建风险指数的交织区拥堵识别方法[J]. 铁道科学与工程学报, 2023, 20(2): 494-505. [LI X Y, LIANG J R, ZHANG W B, et al. Congestion recognition method in weaving sections by constructing risk index based on aerial video [J]. Journal of Railway Science and Engineering, 2023, 20(2): 494-505.]
- [15] AHARON N, ORFAIG R, BOBROVSKY B Z. BoT-SORT: Robust associations multi-pedestrian tracking[DB/OL]. (2022-07-07) [2024-09-25]. <https://arxiv.org/abs/2206.14651>.
- [16] CHEN T, GUESTRIN C. Xgboost: A scalable tree boosting system[C]// New York: Association for Computing Machinery, Proceedings of the 22nd ACM SIGKDD international conference on knowledge discovery and data mining, 2016.
- [17] JOCHER G, CHAURASIA A, QIU J. Ultralytics YOLO [EB/OL]. (2023-11-12) [2024-09-25]. <https://github.com/ultralytics/ultralytics>.